



Universal Benchmarking

Guia Completo de Inteligência Competitiva

Mega Brain AI • JARVIS v2.0 • 2026

1. O Que É o Universal Benchmarking

O Bench Analyst é um sistema de análise comparativa estruturada. A premissa central:
Nunca usar opinião — só dados verificáveis com fonte citada e score quantitativo.

Dois princípios que o diferenciam

- Dual output obrigatório — tudo gera .json (para máquinas) + .md (para humanos)
- Exhaustive over summary — análise longa e detalhada supera resumo superficial

2. Os 5 Tipos de Comparação

Tipo	O que compara	Dimensões de scoring
codebase	Frameworks, repositórios, sistemas	Architecture, Testing, Automation, Extensibility, Code Quality
llm	Modelos de IA (Claude vs GPT vs Gemini...)	Reasoning, Coding, Math, Speed, Cost, Context Window, Tool Use
product	SaaS, ferramentas, plataformas	Features, UX/Design, Pricing, Integration, Support, Market Fit
company	Empresas, concorrentes diretos	Revenue, Market Share, Team, Funding, Technology, Brand
technology	Linguagens, DBs, frameworks técnicos	Maturity, Ecosystem, DX, Performance, Scalability, Community

3. O Pipeline Completo (10 Fases)

Fase	Nome	O que faz
0	DETECT	Detecta automaticamente o tipo de comparação
1	INVENTORY A	Escaneia baseline do sujeito A
2	INVENTORY B	Escaneia baseline do sujeito B
3	MATRIX	Tabela feature-a-feature com paridade (1–5)
4	SCORE	Scoring ponderado multi-dimensão (0–100 por eixo)
5	GAP	Gap analysis bidirecional (o que A tem e B não, e vice-versa)
6	DEEP DIVE	Análise profunda tipo-específica (código, UX, financeiro...)
7	REPORT	Relatório executivo com recomendações
8	BATTLE CARD	1 página de comparação para decisão rápida
9	QUALITY GATE	Validação: fontes citadas, JSONs válidos, evidências presentes

4. Os 3 Níveis de Profundidade

Nível	Comando	Artefatos	Tempo	Quando usar
Quick	*bench-quick X	3	~15 min	Reconhecimento inicial
Standard	*bench-matrix + *bench-score + *bench-gap		~30 min	Decisão estratégica
Full	*bench X vs Y	16+	~60 min	Auditoria completa

5. Artefatos Gerados

Tudo salvo em `docs/bench/{a}-vs-{b}/`

Arquivo	Tipo	Formato	Para quem
metadata.json	Metadados	JSON	Sistema
inventory-A.json / .md	Inventário A	JSON + MD	Arquitetos
inventory-B.json / .md	Inventário B	JSON + MD	Arquitetos
comparison-matrix.json / .md	Matriz comparativa	JSON + MD	Todos
scorecard.json / .md	Scores 0–100 por dimensão	JSON + MD	Liderança
gap-analysis.json / .md	O que falta em cada lado	JSON + MD	Produto
battle-card.md	1 página para decidir na hora	MD	Decisores

Arquivo	Tipo	Formato	Para quem
executive-report.md	Relatório executivo completo	MD	C-Level
deep/ (tipo-específico)	Análise profunda	MD	Especialistas

Deep artifacts por tipo

Tipo	Artefatos deep
codebase	component-comparison, hooks-analysis, absorption-roadmap, migration-playbook
llm	reasoning-eval, coding-eval, cost-analysis, benchmark-compilation
product	feature-comparison, ux-analysis, pricing-analysis, reviews-sentiment
company	market-position, swot-analysis, financial-comparison, team-analysis
technology	maturity-assessment, ecosystem-analysis, dx-comparison, performance-benchmarks

6. Sistema de Paridade (Equivalência)

Cada feature comparada recebe uma classificação de equivalência:

Score	Label	Significado
5/5	Forte	Funcionalidade equivalente, mesma profundidade e cobertura
4/5	Parcial Alta	Equivalente com pequenas diferenças de escopo
3/5	Parcial	Diferenças significativas
2/5	Fraco	Gap substancial
1/5	Sem equivalente	Não existe correspondência direta

7. Todos os Comandos Disponíveis

Pipeline Completo

Comando	Descrição
*bench {A} vs {B}	Pipeline universal completo (10 fases, 16+ artefatos)
*bench-matrix {A} vs {B}	Matriz de comparação universal
*bench-score {A} vs {B}	Scoring quantitativo multi-dimensão
*bench-gap {A} vs {B}	Gap analysis bidirecional
*bench-inventory	Snapshot baseline do sistema atual

Comparações Tipo-Específicas

Comando	Tipo	Dimensões principais
*bench-llm {A} vs {B}	LLM	Reasoning, Coding, Speed, Cost, Context
*bench-product {A} vs {B}	Produto	Features, UX, Pricing, Integration
*bench-company {A} vs {B}	Empresa	Revenue, Market Share, Team, Funding
*bench-tech {A} vs {B}	Tecnologia	Maturity, DX, Ecosystem, Performance

Análise Profunda de Codebase

Comando	Descrição
*bench-quick {X}	Comparação rápida (agentes + workflows) — 3 artefatos
*bench-deep {X}	Deep component-by-component com blocos de código
*bench-hooks {X}	Análise profunda de hooks/subsystems
*bench-trace	Mapa de rastreabilidade comando → task → artefato
*bench-migrate {X}	Playbook de migração do concorrente para o sistema

8. Casos de Uso Concretos

Situação	Comando recomendado
Notion vs ClickUp — qual usar na operação?	*bench-product Notion vs ClickUp
Claude Opus 4 vs GPT-4o — qual no pipeline?	*bench-llm claude-opus-4-7 vs gpt-4o
O que meu concorrente faz melhor que eu?	*bench-company MinhaEmpresa vs Concorrente
React vs Vue para o próximo projeto?	*bench-tech React vs Vue
Absorver features do BMAD para o AIOX?	*bench aiox vs bmad + *bench-gap bmad
Entender gaps antes de uma decisão de produto?	*bench-quick {framework} (Quick, 15 min)
Relatório executivo para apresentar à liderança?	*bench {A} vs {B} (Full pipeline, 60 min)

9. Níveis de Confiança dos Dados

Todo dado coletado recebe um nível de confiança explícito no output:

Nível	Threshold	Fonte	Ação
High	>= 0.9	Repositório local / código real	Usar diretamente
Medium	0.7 – 0.89	Documentação oficial	Verificar pontos críticos

Nível	Threshold	Fonte	Ação
Low	< 0.7	Web / docs incompletos	Validar manualmente antes de decidir

Para comparações de codebase, o Bench Analyst exige clone local do repositório. Nunca estima estrutura — conta os arquivos reais. Se não houver URL do repo, para e pede antes de continuar.

10. O Que Nunca Fazer (Anti-Patterns)

■ Nunca fazer	■ Sempre fazer
Inflar scores para parecer melhor	Reportar gaps honestamente
Resumir quando deveria mostrar código lado a lado	Evidência side-by-side com blocos reais
Afirmar equivalência sem evidência	Citar arquivo, URL ou artefato específico
Ignorar vantagens do concorrente	Documentar gaps E diferenciais
Usar 'melhor/pior' sem delta quantificado	Usar delta de scores numericamente
Gerar só .md sem .json correspondente	Dual output obrigatório (JSON + MD)
Assumir comportamento do concorrente pelo nome	Verificar na fonte (clone local ou docs)